



RELATÓRIO FINAL DE EXECUÇÃO

Tutorial 1 (AWS): Infraestrutura de Ingestão na Nuvem com Terraform

Amazon EC2, RDS PostgreSQL e S3 provisionados como infraestrutura para ingestão

Disciplina: Ecossistema de Big Data

Professor: Leandro Mendes Ferreira

Grupo A

Nome	Matrícula USP
Breno Tostes Garcia	18105650
Gerson Chadi Junior	4360987
Isabella Abreu Comelli	18106391
Fernando Luiz Gomes	18105793
Caetano Sales Carvalho	18105692

São Paulo, 27 de julho de 2026

1. INTRODUÇÃO

A infraestrutura como código permite definir, versionar e reproduzir ambientes computacionais de maneira declarativa. No Tutorial 1, o Terraform foi empregado para estruturar uma topologia de engenharia de dados na AWS, substituindo os contêineres do cenário local por serviços reais de nuvem.

A EC2 foi definida como ambiente de execução das ferramentas de ingestão, o RDS PostgreSQL como fonte transacional e o S3 como repositório de objetos. Essa separação de responsabilidades forneceu a base para as cargas com Meltano e dltHub realizadas posteriormente.

2. BASE DOCUMENTAL E LIMITAÇÕES

A elaboração deste relatório utilizou o Tutorial 1, um relatório técnico-operacional anterior e registros de execução preservados no histórico do projeto. Os resultados também foram confrontados com os Tutoriais 2 e 3, que registraram os mesmos identificadores de EC2, RDS e S3 e comprovaram a utilização efetiva da infraestrutura.

Não estavam disponíveis o arquivo ZIP original das evidências nem um resumo final estruturado do Tutorial 1. Assim, o pacote entregue com este relatório foi reconstruído. Os arquivos nele contidos são sínteses rastreáveis, mas não substituem os logs brutos integrais e as capturas produzidas no momento da execução.

3. OBJETIVOS E CRITÉRIOS DE ACEITE

3.1. Objetivo Geral

Provisionar, configurar e validar uma infraestrutura AWS capaz de suportar pipelines de ingestão, utilizando Terraform no AWS Academy Learner Lab.

3.2. Objetivos Específicos

- Validar credenciais temporárias e a região us-east-1.
- Provisionar EC2, RDS PostgreSQL, S3 e os componentes de rede associados.

- Conectar à EC2 e utilizá-la como ponto de acesso ao RDS privado.
- Executar schema.sql e seed.sql no banco ecommerce.
- Confirmar as contagens de clientes, produtos e vendas.
- Validar o acesso ao bucket S3 e preservar a infraestrutura para os tutoriais dependentes.

3.3.Critérios De Aceite

Tabela 3-1: Critérios de aceite

Critério	Evidência/resultado esperado
Terraform válido	terraform validate aprovado
Infraestrutura registrada	cinco recursos gerenciados no state
EC2 operacional	acesso remoto e perfil IAM disponíveis
RDS operacional	endpoint resolvido e conexão pela EC2
Seed concluído	20 clientes, 15 produtos e 200 vendas
S3 operacional	bucket acessível sem endpoint local
Segurança	ausência de chaves e senhas no código/pacote

4. ARQUITETURA PROVISIONADA

Arquitetura provisionada no Tutorial 1

Infraestrutura como código para suportar os pipelines Meltano e dltHub




Figura 4-1: Arquitetura provisionada no Tutorial 1. Fonte: elaboração própria a partir do tutorial e dos registros consolidados

Tabela 4-1: Componentes da arquitetura

Componente	Função	Configuração consolidada
Terraform	Infraestrutura como código	Versão 1.15.8, provider AWS, região us-east-1
Amazon EC2	Runner para Meltano e dltHub	i-0db119c4f19fd868e; Amazon Linux 2023
Amazon RDS PostgreSQL	Fonte relacional	ingestao-postgres-202607291814498977000000004; banco ecommerce; porta 5432
Amazon S3	Data lake de destino	650379606721-ingestao-lab-202607291814457199000000002
Security Group	Controle de tráfego	SSH para EC2 e PostgreSQL interno
DB Subnet Group	Sub-redes do RDS	VPC padrão do Learner Lab

5. PREPARAÇÃO DO AMBIENTE E CREDENCIAIS

O ambiente local utilizou Windows 11, PowerShell e WSL2 Ubuntu, com Terraform 1.15.8 e AWS CLI 2.36.1. As credenciais do AWS Academy eram temporárias e precisaram ser renovadas quando a sessão do laboratório expirou ou aplicou a política de cancelamento.

- **Comandos de validação do ambiente local**

```
aws sts get-caller-identity
terraform -version
aws --version
```

A chave SSH foi validada separadamente antes da conexão. Em uma revalidação posterior, o acesso direto pela porta 22 apresentou timeout; o EC2 Instance Connect foi utilizado sem ampliar indiscriminadamente a regra de SSH.

6. PROVISIONAMENTO COM TERRAFORM

O fluxo de provisionamento foi composto por terraform init, terraform validate, terraform plan e terraform apply. O state registrou cinco recursos gerenciados e cinco fontes de dados. A infraestrutura final foi posteriormente revalidada sem drift.

Tabela 6-1: Recursos e fontes de dados registrados no estado do Terraform

Tipo	Recurso
data	data.aws_caller_identity.current
data	data.aws_ssm_parameter.al2023
data	data.aws_subnets.default
data	data.aws_subnets.ec2
data	data.aws_vpc.default
aws_db_instance	aws_db_instance.postgres
aws_db_subnet_group	aws_db_subnet_group.ingestao

Tipo	Recurso
aws_instance	aws_instance.runner
aws_s3_bucket	aws_s3_bucket.datalake
aws_security_group	aws_security_group.ingestao

Durante o planejamento ocorreram falhas de resolução DNS dos endpoints da AWS. A investigação repetiu consultas a STS e EC2, e o plan foi retomado somente após a estabilização. Em revalidações posteriores, alterações percebidas no estado foram associadas à expiração das credenciais e à mudança do IP público, não a modificações intencionais da arquitetura.

7. ACESSO À EC2 E VALIDAÇÃO DO RDS

A instância i-0db119c4f19fd868e funcionou como runner e como ponto de acesso ao RDS privado. O endpoint ingestao-postgres-20260729181449897700000004.csoa8fqdbrgu.us-east-1.rds.amazonaws.com foi recuperado do Terraform e validado a partir da EC2. O RDS não foi exposto publicamente, em conformidade com a arquitetura proposta.

- **Comandos principais executados na EC2**

```
nslookup $RDS
psql -h $RDS -U ecommerce -d ecommerce -f schema.sql
psql -h $RDS -U ecommerce -d ecommerce -f seed.sql
```

Tabela 7-1: Resultado do seed do RDS

Tabela	Registros esperados	Registros confirmados	Situação
clientes	20	20	APROVADO
produtos	15	15	APROVADO
vendas	200	200	APROVADO

A carga de 200 vendas foi confirmada novamente nas ingestões dos Tutoriais 2 e 3, proporcionando uma validação cruzada do resultado do seed.

8. VALIDAÇÃO DO AMAZON S3

O bucket 650379606721-ingestao-lab-20260729181445719900000002 foi criado pelo Terraform como data lake real. Antes das cargas posteriores, a listagem não apresentou objetos, comportamento esperado. Nos Tutoriais 2 e 3, o mesmo bucket recebeu os arquivos Parquet e as evidências das pipelines, comprovando sua disponibilidade e a autorização do perfil IAM da EC2.

- **Comandos de validação do bucket**

```
aws s3 ls s3://650379606721-ingestao-lab-20260729181445719900000002/  
aws s3api head-bucket --bucket 650379606721-ingestao-lab-  
20260729181445719900000002
```

A opção `force_destroy` exige cautela: `terraform destroy` remove também os objetos do bucket. A destruição foi, portanto, postergada até a conclusão dos tutoriais dependentes e da guarda local das evidências.

9. SEGURANÇA E RASTREABILIDADE

A arquitetura utilizou as credenciais temporárias do Learner Lab no ambiente local e o perfil IAM da EC2 para operações remotas. O pacote reconstruído não inclui arquivos `credentials`, chaves PEM, `access keys` ou a senha do RDS.

A rastreabilidade é apoiada por um inventário, hashes SHA-256, matriz de conformidade, resumo final e arquivos de síntese por etapa. A indisponibilidade dos logs brutos é registrada explicitamente em todos os artefatos relevantes.

10. DIFICULDADES ENCONTRADAS E SOLUÇÕES ADOTADAS

Tabela 10-1: Dificuldades e soluções

Dificuldade	Solução adotada
Credenciais temporárias expiradas	Reinício do Learner Lab, atualização das credenciais e nova validação pelo STS.
DNS instável no WSL	Testes repetidos de resolução e execução do Terraform apenas após estabilização.
Chave SSH incorreta ou mal localizada	Localização da chave correta, validação pelo OpenSSH e uso do caminho absoluto.
Outputs indisponíveis	Recuperação de IP, endpoint e bucket diretamente pelo terraform state show.
Endpoint do RDS incorreto	Substituição pelo endpoint exato recuperado do estado e teste com nslookup.
RDS privado	Execução do psql e do seed a partir da EC2, dentro da VPC.
Risco de destruição prematura	Postergação do terraform destroy até o fim dos Tutoriais 2 e 3.
Ausência do pacote original	Reconstrução sanitizada e identificação expressa da ressalva documental.

11. AVALIAÇÃO DE CONFORMIDADE COM O TUTORIAL

Tabela 11-1: Matriz de conformidade com o Tutorial 1

Requisito	Implementação	Situação
Provisionar EC2	EC2 runner criada e reutilizada nos Tutoriais 2 e 3	ATENDIDO
Provisionar RDS PostgreSQL	Banco ecommerce privado, acessível pela EC2	ATENDIDO
Provisionar bucket S3	Bucket real criado e posteriormente utilizado	ATENDIDO
Usar Terraform	Estado com cinco recursos gerenciados; validate aprovado	ATENDIDO
Usar IAM do Lab	EC2 associada ao perfil do laboratorio	ATENDIDO
Executar seed	clientes=20, produtos=15, vendas=200	ATENDIDO
Validar o S3	Bucket acessível antes das cargas	ATENDIDO
Usar us-east-1	Região confirmada	ATENDIDO

Requisito	Implementação	Situação
Destruir ao final	Postergado ate a conclusao das atividades dependentes	PENDENTE CONTROLADO
Preservar evidencias	Pacote atual reconstruido; logs brutos originais indisponiveis	ATENDIDO COM RESSALVA

Os requisitos técnicos centrais foram atendidos. A única ressalva diz respeito à preservação documental: o pacote atual é uma reconstrução, e não uma cópia do diretório bruto produzido durante a execução original.

12. RESULTADOS CONSOLIDADOS

Painel de validacao consolidada

Tutorial 1 AWS - infraestrutura final reutilizada pelos Tutoriais 2 e 3




Figura 12-1: Painel de validação consolidada. Fonte: pacote reconstruído de evidências.

Os resultados demonstram que a infraestrutura cumpriu seu propósito. A EC2 foi utilizada como runner nos dois tutoriais seguintes, o RDS forneceu os 200 registros da tabela vendas e o S3 recebeu os conjuntos Parquet produzidos por Meltano e dlthub.

13. CONCLUSÃO E PRÓXIMOS PASSOS

O Tutorial 1 foi concluído tecnicamente com sucesso. O Terraform estruturou uma base de ingestão na AWS, integrando processamento, fonte relacional e armazenamento de objetos. A carga inicial do RDS atingiu as contagens esperadas e os recursos foram efetivamente reutilizados nas etapas posteriores do trabalho.

A reconstrução documental permitiu criar os artefatos que estavam ausentes, mas não elimina a diferença entre uma consolidação posterior e os registros brutos capturados no momento da execução. Essa limitação foi incorporada ao relatório, ao resumo e ao README do pacote.

13.1. Próximos Passos Recomendados

- Guardar localmente o relatório, o resumo e o ZIP reconstruído.
- Publicar no GitHub somente arquivos sem credenciais, chaves e senhas.
- Conferir se os recursos AWS ainda são necessários.
- Após a entrega e a guarda das evidências, executar terraform destroy e confirmar a remoção de EC2, RDS e S3.

14. APÊNDICE A – MAPA DAS EVIDÊNCIAS RECONSTRUÍDAS

Tabela 14-1: Evidências reconstruídas selecionadas

Evidência	Pasta	Conteúdo
E01–E02	01-preparacao	Ambiente e credenciais sanitizadas
E03–E05	02-terraform	Validate/plan, state e outputs
E06	03-ec2	Chave e acesso à EC2
E07–E08	04-rds	Endpoint, seed e contagens
E09	05-s3	Validação do bucket
E10	06-dificuldades	Dificuldades e soluções

Evidência	Pasta	Conteúdo
E11	07-conformidade	Matriz de conformidade
E12-E15	08-validacao-final	Validação, resumo, inventário e hashes

O pacote possui 19 arquivos. A relação completa está em E14_inventario_evidencias.csv e os hashes SHA-256 estão em E15_hashes_evidencias_sha256.csv.

15. APÊNDICE B – NOTA DE RASTREABILIDADE DOCUMENTAL

O pacote original de evidências do Tutorial 1 e o respectivo resumo final não foram localizados. O ZIP entregue foi produzido especificamente para suprir essa ausência e contém arquivos de síntese, não transcrições integrais de cada sessão de terminal.

Os fatos centrais foram triangulados: o tutorial descreve a arquitetura esperada; o relatório anterior registra a execução, as contagens e as dificuldades; e os Tutoriais 2 e 3 confirmam que a EC2, o RDS e o S3 foram efetivamente utilizados. Essa triangulação sustenta o resultado técnico aprovado, mas não permite classificar o pacote como evidência forense original.

Nenhuma credencial temporária, chave privada ou senha foi incorporada ao pacote reconstruído. A preservação dessa separação é prioritária em relação à reprodução literal de comandos que contivessem segredos.